

superstore

April 24, 2026

1 EDA — Superstore Sales Dataset

Análisis exploratorio del dataset `superstore.csv`.

- 9.994 registros de pedidos de una tienda online de EE. UU.
- 4 años de datos (2015–2018)
- 21 columnas: fechas, identificadores, datos geográficos, categorías de producto y las 4 métricas de negocio (`Sales`, `Quantity`, `Discount`, `Profit`).
- Fuente: <https://github.com/leonism/sample-superstore>

1.1 Carga de datos

El CSV tiene tres peculiaridades que hay que gestionar en la carga:

1. Las últimas 806 filas no son ventas — son tablas auxiliares (`People`, `Returns`) que se pegaron al final del archivo. Se detectan porque tienen `Sales` nulo; las filtramos.
2. `Postal Code` viene como número decimal (`float`), con los ceros iniciales comidos. Lo reconstruimos a texto de 5 dígitos.
3. Las fechas vienen en formato americano `m/d/yyyy`.

```
[31]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('superstore.csv')

# 1. Filtramos las filas basura (tablas auxiliares al final)
df = df[df['Sales'].notna()].copy()

# 2. Postal Code: de float a texto con 5 dígitos (rellenando ceros iniciales)
df['Postal Code'] = df['Postal Code'].apply(
    lambda x: str(int(x)).zfill(5) if pd.notna(x) else np.nan
)

# 3. Fechas en formato americano
df['Order Date'] = pd.to_datetime(df['Order Date'], format='%m/%d/%Y')
df['Ship Date'] = pd.to_datetime(df['Ship Date'], format='%m/%d/%Y')
```

```
# 4. Quantity como entero (viene como float por el parseo)
df['Quantity'] = df['Quantity'].astype(int)

print('=' * 60)
print('EXPLORACIÓN COMPLETA - superstore.csv (21 columnas)')
print('=' * 60)
```

```
=====
EXPLORACIÓN COMPLETA - superstore.csv (21 columnas)
=====
```

1.2 1. Dimensiones del dataset

```
[32]: print(f"Filas: {df.shape[0]:,}")
      print(f"Columnas: {df.shape[1]:,}")
```

```
Filas: 9,994
Columnas: 21
```

1.3 2. Primeras y últimas filas

```
[33]: print('PRIMERAS 5 FILAS:')
      print(df.head())

      print('\nÚLTIMAS 5 FILAS:')
      print(df.tail())
```

PRIMERAS 5 FILAS:

	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	\
0	1	CA-2017-152156	2017-11-08	2017-11-11	Second Class	CG-12520	
1	2	CA-2017-152156	2017-11-08	2017-11-11	Second Class	CG-12520	
2	3	CA-2017-138688	2017-06-12	2017-06-16	Second Class	DV-13045	
3	4	US-2016-108966	2016-10-11	2016-10-18	Standard Class	SO-20335	
4	5	US-2016-108966	2016-10-11	2016-10-18	Standard Class	SO-20335	

	Customer Name	Segment	Country	City	...	\
0	Claire Gute	Consumer	United States	Henderson	...	
1	Claire Gute	Consumer	United States	Henderson	...	
2	Darrin Van Huff	Corporate	United States	Los Angeles	...	
3	Sean O'Donnell	Consumer	United States	Fort Lauderdale	...	
4	Sean O'Donnell	Consumer	United States	Fort Lauderdale	...	

	Postal Code	Region	Product ID	Category	Sub-Category	\
0	42420	South	FUR-BO-10001798	Furniture	Bookcases	
1	42420	South	FUR-CH-10000454	Furniture	Chairs	
2	90036	West	OFF-LA-10000240	Office Supplies	Labels	
3	33311	South	FUR-TA-10000577	Furniture	Tables	
4	33311	South	OFF-ST-10000760	Office Supplies	Storage	

	Product Name	Sales	Quantity \
0	Bush Somerset Collection Bookcase	261.9600	2
1	Hon Deluxe Fabric Upholstered Stacking Chairs,...	731.9400	3
2	Self-Adhesive Address Labels for Typewriters b...	14.6200	2
3	Bretford CR4500 Series Slim Rectangular Table	957.5775	5
4	Eldon Fold 'N Roll Cart System	22.3680	2

	Discount	Profit
0	0.00	41.9136
1	0.00	219.5820
2	0.00	6.8714
3	0.45	-383.0310
4	0.20	2.5164

[5 rows x 21 columns]

ÚLTIMAS 5 FILAS:

	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID \
9989	9990	CA-2015-110422	2015-01-21	2015-01-23	Second Class	TB-21400
9990	9991	CA-2018-121258	2018-02-26	2018-03-03	Standard Class	DB-13060
9991	9992	CA-2018-121258	2018-02-26	2018-03-03	Standard Class	DB-13060
9992	9993	CA-2018-121258	2018-02-26	2018-03-03	Standard Class	DB-13060
9993	9994	CA-2018-119914	2018-05-04	2018-05-09	Second Class	CC-12220

	Customer Name	Segment	Country	City ...	Postal Code \
9989	Tom Boeckenhauer	Consumer	United States	Miami ...	33180
9990	Dave Brooks	Consumer	United States	Costa Mesa ...	92627
9991	Dave Brooks	Consumer	United States	Costa Mesa ...	92627
9992	Dave Brooks	Consumer	United States	Costa Mesa ...	92627
9993	Chris Cortes	Consumer	United States	Westminster ...	92683

	Region	Product ID	Category	Sub-Category \
9989	South	FUR-FU-10001889	Furniture	Furnishings
9990	West	FUR-FU-10000747	Furniture	Furnishings
9991	West	TEC-PH-10003645	Technology	Phones
9992	West	OFF-PA-10004041	Office Supplies	Paper
9993	West	OFF-AP-10002684	Office Supplies	Appliances

	Product Name	Sales	Quantity \
9989	Ultra Door Pull Handle	25.248	3
9990	Tenex B1-RE Series Chair Mats for Low Pile Car...	91.960	2
9991	Aastra 57i VoIP phone	258.576	2
9992	It's Hot Message Books with Stickers, 2 3/4" x 5"	29.600	4
9993	Acco 7-Outlet Masterpiece Power Center, Wihtou...	243.160	2

	Discount	Profit
9989	0.2	4.1028
9990	0.0	15.6332

```

9991      0.2  19.3932
9992      0.0  13.3200
9993      0.0  72.9480

```

```
[5 rows x 21 columns]
```

1.4 3. Estructura y tipos de columnas

```
[34]: df.info()
```

```

<class 'pandas.DataFrame'>
RangeIndex: 9994 entries, 0 to 9993
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Row ID                9994 non-null   str
1   Order ID              9994 non-null   str
2   Order Date            9994 non-null   datetime64[us]
3   Ship Date             9994 non-null   datetime64[us]
4   Ship Mode             9994 non-null   str
5   Customer ID           9994 non-null   str
6   Customer Name         9994 non-null   str
7   Segment               9994 non-null   str
8   Country               9994 non-null   str
9   City                  9994 non-null   str
10  State                 9994 non-null   str
11  Postal Code           9983 non-null   str
12  Region                9994 non-null   str
13  Product ID            9994 non-null   str
14  Category              9994 non-null   str
15  Sub-Category          9994 non-null   str
16  Product Name          9994 non-null   str
17  Sales                 9994 non-null   float64
18  Quantity              9994 non-null   int64
19  Discount              9994 non-null   float64
20  Profit                9994 non-null   float64
dtypes: datetime64[us](2), float64(3), int64(1), str(15)
memory usage: 1.6 MB

```

1.5 4. Estadísticas descriptivas y clasificación de variables

Antes de entrar en estadísticas, clasificamos cada columna según su tipo analítico. Esta clasificación guía el resto del análisis: qué estadísticos tiene sentido calcular, qué gráficos usar y qué agrupaciones son válidas.

Identificadores y ruido: - **Row ID** — numérica continua (identificador secuencial, sin valor analítico). - **Order ID** — categórica nominal (identificador de pedido; útil para contar pedidos únicos). - **Country** — categórica nominal (valor constante “United States”, sin poder discriminativo).

Temporales: - `Order Date` — temporal (datetime). Fecha del pedido, base de la evolución y la estacionalidad. - `Ship Date` — temporal (datetime). Fecha de envío, base de `Días Envío`.

Catégoricas ordinales: - `Ship Mode` — catégorica ordinal. Orden: Same Day < First Class < Second Class < Standard Class (velocidad de entrega).

Catégoricas nominales: - `Customer ID` y `Customer Name` — identificadores de cliente (793 valores únicos). - `Segment` — tipo de cliente: Consumer, Corporate, Home Office. - `City` (531), `State` (49), `Postal Code` (630) y `Region` (4) — granularidad geográfica. - `Product ID` (1.862), `Category` (3), `Sub-Category` (17) y `Product Name` (1.850) — jerarquía de producto.

Numéricas continuas: - `Sales` — importe facturado por línea. - `Quantity` — unidades vendidas por línea (sin tope teórico). - `Profit` — beneficio por línea (positivo o negativo).

Numéricas discretas: - `Discount` — política comercial cerrada: solo 12 valores posibles entre 0 y 0,80.

`describe()` a continuación muestra estadísticas solo de las numéricas (las catégoricas se analizan en la sección 6).

```
[35]: print(df.describe())
```

	Order Date	Ship Date	Sales \
count	9994	9994	9994.000000
mean	2017-04-30 05:17:08.056834	2017-05-04 04:17:20.304182	229.858001
min	2015-01-03 00:00:00	2015-01-07 00:00:00	0.444000
25%	2016-05-23 00:00:00	2016-05-27 00:00:00	17.280000
50%	2017-06-26 00:00:00	2017-06-29 00:00:00	54.490000
75%	2018-05-14 00:00:00	2018-05-18 00:00:00	209.940000
max	2018-12-30 00:00:00	2019-01-05 00:00:00	22638.480000
std	NaN	NaN	623.245101

	Quantity	Discount	Profit
count	9994.000000	9994.000000	9994.000000
mean	3.789574	0.156203	28.656896
min	1.000000	0.000000	-6599.978000
25%	2.000000	0.000000	1.728750
50%	3.000000	0.200000	8.666500
75%	5.000000	0.200000	29.364000
max	14.000000	0.800000	8399.976000
std	2.225110	0.206452	234.260108

1.6 5. Valores nulos por columna

Después de filtrar las filas basura (las 806 que correspondían a las tablas auxiliares `People` y `Returns`), solo quedan 11 nulos reales en `Postal Code`, que corresponden a 11 ciudades donde faltaba ese dato en el CSV.

```
[36]: nulos = df.isnull().sum()
pct = (df.isnull().mean() * 100).round(2)
resumen = pd.DataFrame({'nulos': nulos, '%': pct})
```

```
print(resumen.to_string())
```

	nulos	%
Row ID	0	0.00
Order ID	0	0.00
Order Date	0	0.00
Ship Date	0	0.00
Ship Mode	0	0.00
Customer ID	0	0.00
Customer Name	0	0.00
Segment	0	0.00
Country	0	0.00
City	0	0.00
State	0	0.00
Postal Code	11	0.11
Region	0	0.00
Product ID	0	0.00
Category	0	0.00
Sub-Category	0	0.00
Product Name	0	0.00
Sales	0	0.00
Quantity	0	0.00
Discount	0	0.00
Profit	0	0.00

1.7 6. Análisis columna por columna

Para cada columna mostramos tipo, nulos, valores únicos y — según sea numérica o categórica — estadísticas o top 10 valores más frecuentes.

```
[37]: for col in df.columns:
    print(f"\n--- {col} ---")
    print(f" Tipo: {df[col].dtype}")
    print(f" Nulos: {df[col].isnull().sum():,} ({df[col].isnull().mean()*100:.
↪1f}%)")
    print(f" Valores únicos: {df[col].nunique():,}")

    if df[col].dtype in ['int64', 'float64']:
        print(f" Min: {df[col].min()} | Max: {df[col].max()}")
        print(f" Media: {df[col].mean():.2f} | Mediana: {df[col].median():.
↪2f}%)")
        print(f" Desv. estándar: {df[col].std():.2f}")
    else:
        top10 = df[col].value_counts().head(10)
        print(f" Top 10 valores:")
        for val, cnt in top10.items():
            print(f" {val}: {cnt:,} ({cnt/len(df)*100:.1f}%)")
```

--- Row ID ---

Tipo: str

Nulos: 0 (0.0%)

Valores únicos: 9,994

Top 10 valores:

1: 1 (0.0%)
2: 1 (0.0%)
3: 1 (0.0%)
4: 1 (0.0%)
5: 1 (0.0%)
6: 1 (0.0%)
7: 1 (0.0%)
8: 1 (0.0%)
9: 1 (0.0%)
10: 1 (0.0%)

--- Order ID ---

Tipo: str

Nulos: 0 (0.0%)

Valores únicos: 5,009

Top 10 valores:

CA-2018-100111: 14 (0.1%)
CA-2018-157987: 12 (0.1%)
US-2017-108504: 11 (0.1%)
CA-2017-165330: 11 (0.1%)
CA-2016-131338: 10 (0.1%)
US-2016-126977: 10 (0.1%)
CA-2017-105732: 10 (0.1%)
CA-2018-117457: 9 (0.1%)
CA-2015-106439: 9 (0.1%)
CA-2016-164882: 9 (0.1%)

--- Order Date ---

Tipo: datetime64[us]

Nulos: 0 (0.0%)

Valores únicos: 1,236

Top 10 valores:

2017-09-05 00:00:00: 38 (0.4%)
2018-09-02 00:00:00: 36 (0.4%)
2017-11-10 00:00:00: 35 (0.4%)
2018-12-01 00:00:00: 34 (0.3%)
2018-12-02 00:00:00: 34 (0.3%)
2018-12-09 00:00:00: 33 (0.3%)
2018-11-12 00:00:00: 30 (0.3%)
2018-12-08 00:00:00: 30 (0.3%)
2018-09-09 00:00:00: 29 (0.3%)
2017-12-11 00:00:00: 28 (0.3%)

```

--- Ship Date ---
Tipo: datetime64[us]
Nulos: 0 (0.0%)
Valores únicos: 1,334
Top 10 valores:
  2016-12-16 00:00:00: 35 (0.4%)
  2018-09-26 00:00:00: 34 (0.3%)
  2018-11-21 00:00:00: 32 (0.3%)
  2018-12-06 00:00:00: 32 (0.3%)
  2018-09-15 00:00:00: 30 (0.3%)
  2018-12-12 00:00:00: 30 (0.3%)
  2018-09-06 00:00:00: 30 (0.3%)
  2015-09-13 00:00:00: 27 (0.3%)
  2018-09-08 00:00:00: 27 (0.3%)
  2017-09-07 00:00:00: 26 (0.3%)

```

```

--- Ship Mode ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 4
Top 10 valores:
  Standard Class: 5,968 (59.7%)
  Second Class: 1,945 (19.5%)
  First Class: 1,538 (15.4%)
  Same Day: 543 (5.4%)

```

```

--- Customer ID ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 793
Top 10 valores:
  WB-21850: 37 (0.4%)
  MA-17560: 34 (0.3%)
  JL-15835: 34 (0.3%)
  PP-18955: 34 (0.3%)
  JD-15895: 32 (0.3%)
  CK-12205: 32 (0.3%)
  SV-20365: 32 (0.3%)
  EH-13765: 32 (0.3%)
  EP-13915: 31 (0.3%)
  ZC-21910: 31 (0.3%)

```

```

--- Customer Name ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 793
Top 10 valores:

```


William Brown: 37 (0.4%)
Matt Abelman: 34 (0.3%)
John Lee: 34 (0.3%)
Paul Prost: 34 (0.3%)
Jonathan Doherty: 32 (0.3%)
Chloris Kastensmidt: 32 (0.3%)
Seth Vernon: 32 (0.3%)
Edward Hooks: 32 (0.3%)
Emily Phan: 31 (0.3%)
Zuschuss Carroll: 31 (0.3%)

--- Segment ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 3
Top 10 valores:
Consumer: 5,191 (51.9%)
Corporate: 3,020 (30.2%)
Home Office: 1,783 (17.8%)

--- Country ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 1
Top 10 valores:
United States: 9,994 (100.0%)

--- City ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 531
Top 10 valores:
New York City: 915 (9.2%)
Los Angeles: 747 (7.5%)
Philadelphia: 537 (5.4%)
San Francisco: 510 (5.1%)
Seattle: 428 (4.3%)
Houston: 377 (3.8%)
Chicago: 314 (3.1%)
Columbus: 222 (2.2%)
San Diego: 170 (1.7%)
Springfield: 163 (1.6%)

--- State ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 49
Top 10 valores:

California: 2,001 (20.0%)
New York: 1,128 (11.3%)
Texas: 985 (9.9%)
Pennsylvania: 587 (5.9%)
Washington: 506 (5.1%)
Illinois: 492 (4.9%)
Ohio: 469 (4.7%)
Florida: 383 (3.8%)
Michigan: 255 (2.6%)
North Carolina: 249 (2.5%)

--- Postal Code ---

Tipo: str
Nulos: 11 (0.1%)
Valores únicos: 630
Top 10 valores:
10035: 263 (2.6%)
10024: 230 (2.3%)
10009: 229 (2.3%)
94122: 203 (2.0%)
10011: 193 (1.9%)
94110: 166 (1.7%)
98105: 165 (1.7%)
19134: 160 (1.6%)
98103: 151 (1.5%)
90049: 151 (1.5%)

--- Region ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 4
Top 10 valores:
West: 3,203 (32.0%)
East: 2,848 (28.5%)
Central: 2,323 (23.2%)
South: 1,620 (16.2%)

--- Product ID ---

Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 1,862
Top 10 valores:
OFF-PA-10001970: 19 (0.2%)
TEC-AC-10003832: 18 (0.2%)
FUR-FU-10004270: 16 (0.2%)
FUR-CH-10001146: 15 (0.2%)
TEC-AC-10003628: 15 (0.2%)
FUR-CH-10002647: 15 (0.2%)

```

    TEC-AC-10002049: 15 (0.2%)
    OFF-PA-10002377: 14 (0.1%)
    OFF-BI-10001524: 14 (0.1%)
    OFF-BI-10004632: 14 (0.1%)

--- Category ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 3
Top 10 valores:
    Office Supplies: 6,026 (60.3%)
    Furniture: 2,121 (21.2%)
    Technology: 1,847 (18.5%)

--- Sub-Category ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 17
Top 10 valores:
    Binders: 1,523 (15.2%)
    Paper: 1,370 (13.7%)
    Furnishings: 957 (9.6%)
    Phones: 889 (8.9%)
    Storage: 846 (8.5%)
    Art: 796 (8.0%)
    Accessories: 775 (7.8%)
    Chairs: 617 (6.2%)
    Appliances: 466 (4.7%)
    Labels: 364 (3.6%)

--- Product Name ---
Tipo: str
Nulos: 0 (0.0%)
Valores únicos: 1,850
Top 10 valores:
    Staple envelope: 48 (0.5%)
    Easy-staple paper: 46 (0.5%)
    Staples: 46 (0.5%)
    Avery Non-Stick Binders: 20 (0.2%)
    Staples in misc. colors: 19 (0.2%)
    Staple remover: 18 (0.2%)
    KI Adjustable-Height Table: 18 (0.2%)
    Storex Dura Pro Binders: 17 (0.2%)
    Staple-based wall hangings: 16 (0.2%)
    Logitech 910-002974 M325 Wireless Mouse for Web Scrolling: 15 (0.2%)

--- Sales ---
Tipo: float64

```

```

Nulos: 0 (0.0%)
Valores únicos: 5,825
Min: 0.444 | Max: 22638.48
Media: 229.86 | Mediana: 54.49
Desv. estándar: 623.25

--- Quantity ---
Tipo: int64
Nulos: 0 (0.0%)
Valores únicos: 14
Min: 1 | Max: 14
Media: 3.79 | Mediana: 3.00
Desv. estándar: 2.23

--- Discount ---
Tipo: float64
Nulos: 0 (0.0%)
Valores únicos: 12
Min: 0.0 | Max: 0.8
Media: 0.16 | Mediana: 0.20
Desv. estándar: 0.21

--- Profit ---
Tipo: float64
Nulos: 0 (0.0%)
Valores únicos: 7,287
Min: -6599.978 | Max: 8399.976
Media: 28.66 | Mediana: 8.67
Desv. estándar: 234.26

```

1.8 7. Matriz de correlaciones

Correlación entre las 4 variables numéricas de negocio (Sales, Quantity, Discount, Profit). Nos interesa sobre todo ver cómo Discount se relaciona con Profit y si Sales correlaciona con Quantity.

```

[38]: cols_corr = df.select_dtypes(include=[np.number]).columns.tolist()
      # Excluimos Row ID porque es un identificador y su correlación no tiene sentido
      cols_corr = [c for c in cols_corr if c != 'Row ID']
      print(df[cols_corr].corr().round(2).to_string())


```

	Sales	Quantity	Discount	Profit
Sales	1.00	0.20	-0.03	0.48
Quantity	0.20	1.00	0.01	0.07
Discount	-0.03	0.01	1.00	-0.22
Profit	0.48	0.07	-0.22	1.00

1.8.1 7.1 Heatmap de correlaciones

La misma matriz anterior en formato visual: azul cuando la correlación es positiva, rojo cuando es negativa, más intenso cuanto más cerca del ± 1 . Se lee de un vistazo y resalta los pares de variables que se mueven juntas o en direcciones opuestas.

```
[39]: plt.figure(figsize=(7, 5))
sns.heatmap(
    df[cols_corr].corr(),
    annot=True,
    fmt='.2f',
    cmap='coolwarm',
    center=0,
    vmin=-1,
    vmax=1,
    square=True
)
plt.title('Matriz de correlaciones')
plt.tight_layout()
plt.show()
```



1.9 Limpieza final y conversión de tipos

- Eliminamos las 11 filas con Postal Code nulo (0,11 % del total).
- Convertimos Postal Code a tipo `category` (más eficiente en memoria y conceptualmente correcto).

```
[40]: df = df.dropna(subset=['Postal Code'])
df['Postal Code'] = df['Postal Code'].astype('category')

df.info()
```

```
<class 'pandas.DataFrame'>
Index: 9983 entries, 0 to 9993
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Row ID                9983 non-null   str
1   Order ID              9983 non-null   str
2   Order Date            9983 non-null   datetime64[us]
3   Ship Date             9983 non-null   datetime64[us]
4   Ship Mode             9983 non-null   str
5   Customer ID           9983 non-null   str
6   Customer Name         9983 non-null   str
7   Segment               9983 non-null   str
8   Country               9983 non-null   str
9   City                  9983 non-null   str
10  State                 9983 non-null   str
11  Postal Code           9983 non-null   category
12  Region                9983 non-null   str
13  Product ID            9983 non-null   str
14  Category              9983 non-null   str
15  Sub-Category          9983 non-null   str
16  Product Name          9983 non-null   str
17  Sales                  9983 non-null   float64
18  Quantity              9983 non-null   int64
19  Discount              9983 non-null   float64
20  Profit                9983 non-null   float64
dtypes: category(1), datetime64[us](2), float64(3), int64(1), str(14)
memory usage: 1.6 MB
```

1.10 8. Análisis de fechas y variables derivadas

Creamos métricas de negocio que no vienen explícitas en el CSV:

- **ventas_mensuales** — suma de Sales por mes.
- **ventas_anuales** — suma de Sales por año.

- **pedidos_anuales** — número de pedidos únicos (Order IDs distintos) por año. Clave: un mismo pedido puede aparecer en varias filas si tiene varios productos.
- **ticket_medio_anual** = ventas_anuales / pedidos_anuales. Cuánto gasta un cliente de media en cada compra.
- **Días Envío** — diferencia en días entre Ship Date y Order Date.

```
[41]: ventas_mensuales = df.groupby(df['Order Date'].dt.to_period('M'))['Sales'].sum()
ventas_anuales = df.groupby(df['Order Date'].dt.year)['Sales'].sum()
pedidos_anuales = df.groupby(df['Order Date'].dt.year)['Order ID'].nunique()
ticket_medio_anual = ventas_anuales / pedidos_anuales

df['Días Envío'] = (df['Ship Date'] - df['Order Date']).dt.days

print('VENTAS MENSUALES:')
print(ventas_mensuales)
print('\nVENTAS ANUALES:')
print(ventas_anuales)
print('\nPEDIDOS ÚNICOS ANUALES:')
print(pedidos_anuales)
print('\nTICKET MEDIO ANUAL:')
print(ticket_medio_anual.round(2))
print('\nDÍAS DE ENVÍO - estadísticas:')
print(df['Días Envío'].describe().round(2))
```

VENTAS MENSUALES:

Order Date

2015-01	14236.8950
2015-02	4519.8920
2015-03	55691.0090
2015-04	28295.3450
2015-05	23648.2870
2015-06	34595.1276
2015-07	33946.3930
2015-08	27909.4685
2015-09	81777.3508
2015-10	31453.3930
2015-11	78628.7167
2015-12	69545.6205
2016-01	18174.0756
2016-02	11951.4110
2016-03	38726.2520
2016-04	34195.2085
2016-05	30131.6865
2016-06	24797.2920
2016-07	28765.3250
2016-08	36898.3322
2016-09	64595.9180
2016-10	31404.9235

2016-11	70852.4635
2016-12	74919.5212
2017-01	16870.1810
2017-02	22978.8150
2017-03	51715.8750
2017-04	37455.2890
2017-05	56987.7280
2017-06	40344.5340
2017-07	39261.9630
2017-08	31115.3743
2017-09	73410.0249
2017-10	59687.7450
2017-11	79411.9658
2017-12	96999.0430
2018-01	43334.1940
2018-02	20301.1334
2018-03	58872.3528
2018-04	36521.5361
2018-05	44261.1102
2018-06	52981.7257
2018-07	45264.4160
2018-08	63120.8880
2018-09	87866.6520
2018-10	77776.9232
2018-11	118447.8250
2018-12	83624.2888

Freq: M, Name: Sales, dtype: float64

VENTAS ANUALES:

Order	Date
2015	484247.4981
2016	465412.4090
2017	606238.5380
2018	732373.0452

Name: Sales, dtype: float64

PEDIDOS ÚNICOS ANUALES:

Order	Date
2015	969
2016	1036
2017	1313
2018	1685

Name: Order ID, dtype: int64

TICKET MEDIO ANUAL:

Order	Date
2015	499.74
2016	449.24


```
2017    461.72
2018    434.64
dtype: float64
```

DÍAS DE ENVÍO - estadísticas:

```
count    9983.00
mean      3.96
std       1.75
min       0.00
25%       3.00
50%       4.00
75%       5.00
max       7.00
```

Name: Dias Envio, dtype: float64

1.11 9. Visualizaciones

Elegimos el gráfico según el tipo de variable:

- Categórica con pocos valores (20) → countplot
- Categórica con muchos valores → barplot del top N
- Numérica muy sesgada → histograma en escala log
- Temporal (fechas) → lineplot agrupado por mes/año
- Numérica cruzada con categórica → boxplot
- Dos numéricas → scatterplot

```
[42]: sns.set_theme(style='whitegrid', palette='deep')
```

1.11.1 9.1 Categóricas con pocos niveles → countplot



Ship Mode es la única categórica ordinal del grupo, así que la graficamos aparte con su orden natural (de más rápido a más lento) en lugar de ordenarla por frecuencia.




```
[43]: # Ship Mode - categórica ordinal: ordenada por velocidad de entrega
plt.figure(figsize=(10, 4))
sns.countplot(
    data=df, y='Ship Mode',
    order=['Same Day', 'First Class', 'Second Class', 'Standard Class']
)
plt.title('Distribución de Ship Mode (orden: más rápido → más lento)')
plt.xlabel('Nº de filas')
plt.tight_layout()
plt.show()

# Resto - categóricas nominales: ordenadas por frecuencia
cat_pocas = ['Segment', 'Region', 'Category', 'Sub-Category']

for col in cat_pocas:
    plt.figure(figsize=(10, 4))
```


```
orden = df[col].value_counts().index
sns.countplot(data=df, y=col, order=orden)
plt.title(f'Distribución de {col}')
plt.xlabel('Nº de filas')
plt.tight_layout()
plt.show()
```







1.11.2 9.2 Categóricas con muchos niveles → top 15


```
[44]: for col, top_n in [('State', 15), ('City', 15), ('Postal Code', 15)]:  
    plt.figure(figsize=(10, 6))  
    top = df[col].value_counts().head(top_n)  
    sns.barplot(x=top.values, y=top.index.astype(str))  
    plt.title(f'Top {top_n} {col} por número de pedidos')  
    plt.xlabel('Nº de filas')  
    plt.tight_layout()  
    plt.show()
```





1.11.3 9.3 Distribución de Sales → histograma en escala log


```
[45]: plt.figure(figsize=(10, 4))
sns.histplot(df['Sales'], bins=50, log_scale=True)
plt.title('Distribución de Sales (escala log)')
plt.xlabel('Sales ($)')
plt.tight_layout()
plt.show()
```



1.11.4 9.4 Distribución de Quantity → countplot

Aunque Quantity es numérica continua, en la práctica toma muy pocos valores únicos en el dataset (del 1 al 14). Usamos un countplot para ver la distribución con más claridad que un histograma.


```
[46]: plt.figure(figsize=(10, 4))
sns.countplot(data=df, x='Quantity')
plt.title('Distribución de Quantity (unidades por línea de pedido)')
plt.xlabel('Unidades')
plt.ylabel('Nº de filas')
plt.tight_layout()
plt.show()
```



1.11.5 9.5 Distribución de Discount → countplot

Discount es numérica discreta con solo 12 valores posibles (catálogo cerrado de descuentos). El countplot muestra cuántas ventas corresponden a cada tramo.

```
[47]: plt.figure(figsize=(10, 4))
sns.countplot(data=df, x='Discount')
plt.title('Distribución de Discount')
plt.xlabel('Descuento aplicado')
plt.ylabel('Nº de filas')
plt.tight_layout()
plt.show()
```




1.11.6 9.6 Distribución de Profit → histograma con escala symlog

Profit tiene valores negativos (pérdidas) además de positivos, y su rango es enorme (-6.600 a +8.400). Usamos escala `symlog` que comprime los extremos pero permite valores negativos, a

diferencia de la escala log pura. Calculamos los bins manualmente en escala logarítmica para que cada barra ocupe el espacio correcto en el eje (con `histplot` y bins automáticos las barras se apilotonarían cerca del 0).

```
[48]: # Bins simétricos en escala log: cada bin ocupa una franja proporcional en el
      ↪ eje symlog
abs_max = max(abs(df['Profit'].min()), abs(df['Profit'].max()))
log_max = np.ceil(np.log10(abs_max))
positivos = np.logspace(-1, log_max, 30)
negativos = -positivos[::-1]
bins = np.concatenate([negativos, [0], positivos])

plt.figure(figsize=(10, 4))
plt.hist(df['Profit'], bins=bins, edgecolor='white', linewidth=0.3)
plt.xscale('symlog')
plt.axvline(0, color='red', linewidth=0.8, linestyle='--')
plt.title('Distribución de Profit (escala symlog)')
plt.xlabel('Profit ($)')
plt.ylabel('Count')
plt.tight_layout()
plt.show()
```




1.11.7 9.7 Serie temporal → ventas mensuales por Order Date

```
[49]: ventas_mensuales_ts = ventas_mensuales.copy()
      ventas_mensuales_ts.index = ventas_mensuales_ts.index.to_timestamp()

      plt.figure(figsize=(14, 4))
      sns.lineplot(x=ventas_mensuales_ts.index, y=ventas_mensuales_ts.values)
      plt.title('Ventas mensuales por Order Date')
      plt.ylabel('Sales ($)')
      plt.xlabel('Mes')
```




```
plt.tight_layout()
plt.show()
```



1.11.8 9.8 Días de envío por modalidad → boxplot

```
[50]: plt.figure(figsize=(10, 4))
sns.boxplot(
    data=df,
    x='Ship Mode',
    y='Dias Envio',
    order=['Same Day', 'First Class', 'Second Class', 'Standard Class']
)
plt.title('Días de envío por modalidad')
plt.ylabel('Días')
plt.tight_layout()
plt.show()
```



1.12 10. Variables derivadas anuales

```
[51]: fig, axes = plt.subplots(1, 3, figsize=(18, 4))

sns.barplot(x=ventas_anuales.index, y=ventas_anuales.values, ax=axes[0])
axes[0].set_title('Ventas totales por año')
axes[0].set_ylabel('Sales ($)')
axes[0].set_xlabel('Año')

sns.barplot(x=pedidos_anuales.index, y=pedidos_anuales.values, ax=axes[1],
            color='seagreen')
axes[1].set_title('Pedidos únicos por año')
axes[1].set_ylabel('Nº pedidos')
axes[1].set_xlabel('Año')

sns.barplot(x=ticket_medio_anual.index, y=ticket_medio_anual.values,
            ax=axes[2], color='indianred')
axes[2].set_title('Ticket medio anual')
axes[2].set_ylabel('Sales / pedido ($)')
axes[2].set_xlabel('Año')

plt.tight_layout()
plt.show()
```




1.13 11. Productos: precio vs volumen

1.13.1 11.1 Top 15 productos con mayor precio medio de venta

```
[52]: precio_medio = df.groupby('Product Name')['Sales'].mean().
        sort_values(ascending=False).head(15)


plt.figure(figsize=(10, 6))
sns.barplot(x=precio_medio.values, y=precio_medio.index)
plt.title('Top 15 productos con mayor precio medio de venta')
plt.xlabel('Precio medio por venta ($)')
plt.tight_layout()
plt.show()
```



1.13.2 11.2 Top 15 productos por ingresos totales

```
[53]: ingresos = df.groupby('Product Name')['Sales'].sum().
      ↪sort_values(ascending=False).head(15)


plt.figure(figsize=(10, 6))
sns.barplot(x=ingresos.values, y=ingresos.index)
plt.title('Top 15 productos por ingresos totales')
plt.xlabel('Ventas totales ($)')
plt.tight_layout()
plt.show()
```



1.13.3 11.3 Precio medio por Sub-Category

```
[54]: precio_por_subcat = df.groupby('Sub-Category')['Sales'].mean().
      ↪sort_values(ascending=False)

plt.figure(figsize=(10, 5))
sns.barplot(x=precio_por_subcat.values, y=precio_por_subcat.index)
plt.title('Precio medio por Sub-Category')
plt.xlabel('Precio medio ($)')
plt.tight_layout()
plt.show()
```




1.13.4 11.4 Scatterplot: volumen vs precio medio por Sub-Category

```
[55]: resumen = df.groupby('Sub-Category').agg(
    precio_medio=('Sales', 'mean'),
    n_ventas=('Sales', 'count')
).reset_index()

plt.figure(figsize=(10, 6))
sns.scatterplot(data=resumen, x='n_ventas', y='precio_medio', s=100)

for _, row in resumen.iterrows():
    plt.annotate(
        row['Sub-Category'],
        (row['n_ventas'], row['precio_medio']),
        fontsize=8,
        xytext=(5, 5),
        textcoords='offset points'
    )

plt.title('Volumen vs precio medio por Sub-Category')
plt.xlabel('Nº de ventas')
plt.ylabel('Precio medio ($)')
plt.tight_layout()
plt.show()
```




1.14 12. Análisis de rentabilidad

Usamos las columnas `Quantity`, `Discount` y `Profit` para responder preguntas que solo con `Sales` no se pueden contestar: qué productos dan dinero de verdad, qué descuentos son asumibles y cuáles destruyen el margen.

1.14.1 12.1 Profit total por Sub-Category

```
[56]: profit_subcat = df.groupby('Sub-Category')['Profit'].sum().
      ↪sort_values(ascending=False)

plt.figure(figsize=(10, 5))
colors = ['seagreen' if v > 0 else 'indianred' for v in profit_subcat.values]
plt.barh(profit_subcat.index, profit_subcat.values, color=colors)
plt.gca().invert_yaxis()
plt.title('Profit total por Sub-Category')
plt.xlabel('Profit ($)')
plt.axvline(0, color='black', linewidth=0.5)
plt.tight_layout()
plt.show()
```




1.14.2 12.2 Facturación vs rentabilidad por Sub-Category

```
[57]: resumen_rent = df.groupby('Sub-Category').agg(
    sales=('Sales', 'sum'),
    profit=('Profit', 'sum')
).reset_index()

plt.figure(figsize=(10, 6))
colors = ['seagreen' if p > 0 else 'indianred' for p in resumen_rent['profit']]
plt.scatter(resumen_rent['sales'], resumen_rent['profit'], s=100, c=colors)

for _, row in resumen_rent.iterrows():
    plt.annotate(
        row['Sub-Category'],
        (row['sales'], row['profit']),
        fontsize=8,
        xytext=(5, 5),
        textcoords='offset points'
    )

plt.axhline(0, color='black', linewidth=0.5)
plt.title('Facturación vs rentabilidad por Sub-Category')
plt.xlabel('Ventas totales ($)')
plt.ylabel('Profit total ($)')
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```



1.14.3 12.3 Relación descuento vs rentabilidad


```
[58]: # Agrupamos por tramos de descuento y vemos el profit medio en cada tramo
bins = [-0.01, 0.01, 0.1, 0.2, 0.3, 0.5, 0.8]
labels = ['0%', '1-10%', '10-20%', '20-30%', '30-50%', '50-80%']
df['Tramo Descuento'] = pd.cut(df['Discount'], bins=bins, labels=labels)

profit_por_descuento = df.groupby('Tramo Descuento', observed=True)['Profit'].
    .agg(['mean', 'sum', 'count'])
print(profit_por_descuento.round(2))

plt.figure(figsize=(10, 5))
colors = ['seagreen' if v > 0 else 'indianred' for v in
    profit_por_descuento['mean']]
plt.bar(profit_por_descuento.index.astype(str), profit_por_descuento['mean'],
    color=colors)
plt.title('Profit medio por tramo de descuento')
plt.ylabel('Profit medio por venta ($)')
plt.xlabel('Descuento aplicado')
plt.axhline(0, color='black', linewidth=0.5)
plt.tight_layout()
plt.show()
```

	mean	sum	count
Tramo Descuento			
0%	66.59	318742.62	4787

1-10%	96.06	9029.18	94
10-20%	24.74	91756.30	3709
20-30%	-45.68	-10369.28	227
30-50%	-156.28	-48447.73	310
50-80%	-89.44	-76559.05	856



1.14.4 12.4 Top 10 productos más rentables y menos rentables

```
[59]: profit_producto = df.groupby('Product Name')['Profit'].sum().
      ↪sort_values(ascending=False)


top_10 = profit_producto.head(10)
bottom_10 = profit_producto.tail(10).sort_values()

fig, axes = plt.subplots(1, 2, figsize=(18, 5))

sns.barplot(x=top_10.values, y=top_10.index, ax=axes[0], color='seagreen')
axes[0].set_title('Top 10 productos más rentables')
axes[0].set_xlabel('Profit total ($)')

sns.barplot(x=bottom_10.values, y=bottom_10.index, ax=axes[1],
      ↪color='indianred')
axes[1].set_title('Top 10 productos menos rentables (pérdidas)')
axes[1].set_xlabel('Profit total ($)')

plt.tight_layout()
plt.show()
```



1.14.5 12.5 Distribución del margen porcentual por nivel de descuento → boxplot

En vez de graficar **Profit** absoluto (en dólares), usamos el **margen porcentual** ($\text{Profit} / \text{Sales} \times 100$). Razón: un descuento alto puede generar una pérdida pequeña en dólares si el producto es barato, y eso distorsiona la lectura visual del **Profit** absoluto. El margen porcentual normaliza todas las ventas a una escala común — lo que importa no es cuánto se pierde en euros, sino qué fracción del precio de venta se destruye.

Con margen porcentual, el descenso es monótono: a más descuento, más destrucción de valor relativo. No hay trampa visual.

```
[60]: # Calculamos margen porcentual por línea de venta
df['Margen'] = df['Profit'] / df['Sales'] * 100

plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='Discount', y='Margen')
plt.axhline(0, color='red', linewidth=0.8, linestyle='--')
plt.title('Distribución del margen porcentual por nivel de descuento')
plt.xlabel('Descuento aplicado')
plt.ylabel('Margen (%)')
plt.tight_layout()
plt.show()
```

